[소프트웨어학과]

영상인식을 위한 ViT, CNN 모델 관련 연구

[최종보고서]

Version 1.0
2023. 12. 21

학번: 201920811

이름: 이동현

지도교수: 유종빈 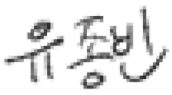

목 차

요약

자기주도연구 1 에 이어 최신 Vision transformer 와 Convolutional neural networks 기반의 아키텍처에 대한 심화된 이해와 실습을 통해 새로운 모델과 새로운 데이터 증강 기법을 각각 하나씩 제안해보는 것을 목표로 연구를 진행하였다. 중간 연구기간(2023.09.01 - 2023.10.12) 동안에는 최대한 많은 아이디어를 생각해내는 것에 중점을 두어 ResNet50[1]을 바탕으로 Dataset Order, Data Filtering 에 대해 실험하였고, DyTox[2] 모델을 바탕으로 Learnable ClassAttention, gumbel softmax, knowledge distillation 을 실험하였다. 7 번의 실패 끝에 현재는 DyTox 에 매 task 별로 기존 데이터와 새로운 데이터를 번갈아가며 학습시키는 Intentional Forgetting 기법을 발견하였으며 이 방법론을 여러 모델들에 적용시켜보았다. Train Data 의 Statistics 를 이용하여 모든 모델에 통할 수 있도록 방법론을 개선시키는 연구를 진행하고 있다.

[1] He et al., 2016, Deep Residual Learning for Image Recognition, https://arxiv.org/abs/1512.03385

[2] Arthur Douillard et al., 2021, DyTox: Transformers for Continual Learning with DYnamic TOken eXpansion, https://arxiv.org/abs/2111.11326

1. 개요

본 연구의 목적은 자기주도연구 1 에서 여러 논문을 읽고 축적한 최신 Vision transformer 와 Convolutional neural networks 기반의 아키텍처에 대한 심화된 이해를 바탕으로, 여러가지 실습과 실험을 통해 새로운 학습의 패러다임을 제안해보는 것이다. 여기서 학습의 패러다임은 새로운 모델이 될 수도 있고, 새로운 데이터 증강기법이 될 수도 있고 새로운 학습 방식이 될 수도 있다.

중간 연구기간(2023.09.01 – 2023.10.12) 동안에는 한 가지 방식을 끝까지 고수하기 보다는 문제를 찾아내고 그것을 해결하기 위해 최대한 많은 아이디어를 생각해내고, 직접 구현해보는 것에 집중하였다. 그 결과 7 번의 실패 끝에 Intentional Forgetting 이라는 기법을 찾아냈고, 기말 연구기간(2023.10.27 – 2023.12.14) 동안에는 이 기법을 다른 모델들을 재현하고 적용시켜보는 과정을 거치고, 모든 모델들에 통할 수 있는 공통된 방법을 찾기 위해 연구하였다.

매주 연구 진행 과정은 Github Repository[3]에서 확인할 수 있다. 주기적인 지도교수 면담으로 진행상황을 파악하고 조율하였으며, 대학원생 멘토와 지속적으로 협력하여 연구를 진행하였다.

2. CNN 실험

CNN 실험들은 ResNet 모델과 CIFAR-100 Dataset[4]을 기준으로 이루어졌다.

2-1. Dataset Order

제일 처음 떠올린 개선 방안은 Dataset 의 순서를 정해주는 것이었다. 현재 대부분의 Data Loader 에서는 Data 를 Random 하게 Shuffle 된 순서로 제시한다. 그런데 개인적으로 진행한 Continual Learning 과 관련된 실험[5]에서는 하나의 Class 만을 담은 Batch 를 학습시키면 모델은 금방 그 Class 만을 예측하도록 변경된다.

그렇다면 Shuffle 되었을 때 해당 Batch 에 포함되지 않은 Class 에 대해서 순간적으로 Forgetting 이 일어날 수도 있겠다는 생각이 들었다. 또한 매 학습마다 Shuffle 을 시킨다면 학습마다 결과에 조금씩 차이가 있을 것이고, 그렇다면 최고의 결과가 나왔을 때 학습 순서를 파악하고 분석하면 학습에 도움이 되지 않을까 생각했다.

실험을 위해 Batch Size 는 Class 수의 배수 (Cifar-100 에서는 100 의 배수)로 설정하였고, 매 Batch 별로 모든 Class 가 한 번씩 나오도록 구현하였다. 다른 Hyperparameter 들은 모두 똑같이 유지하였다.

---

[3] https://github.com/Chihiro0623/Undergraduate-Research-II

[4] https://www.cs.toronto.edu/~kriz/cifar.html

[5] https://github.com/Chihiro0623/ContinualLearning/tree/main/Experiments/experiment1/experiment1-1

먼저 ResNet18, Batch Size 100 에서 좋은 결과[6]가 나왔다. 이에 좀 더 큰 모델인 ResNet50 에서도 잘 작동하는지 확인해보기 위해 추가적인 실험을 진행하였다. 이미지 사이즈를 224 와 32 사이에서 바꿔보고, Batch Normalization 에 다양한 Sample 들이 골고루 들어갈 수 있도록 epoch 마다 Class 별 등장 순서를 Shuffle 하기도 하였다. 그 결과[7], Image Size 가 32 일 때에는 성능이 저하되었으나, 224 일 때에는 약 1.7%p 의 성능 향상을 볼 수 있었다.

그런데 Baseline 의 정확도가 76.75 로 너무 낮기 때문에 좀 더 좋은 Hyperparameter 를 Baseline 으로 교체해보라는 대학원생 멘토의 조언을 듣고, Batch 100 에서 79.21 의 정확도를 내는 모델을 Baseline 으로 재설정하였다. 그런데 코드를 새로 만들던 중, 이전의 결과는 학습 데이터를 두 배로 학습하였기 때문에 좋은 결과를 내고 있었다는 점이 발견되었고, 그 점을 수정한 결과 성능은 Baseline 보다 떨어지게 되었다.

그런데 Accuracy 는 떨어지지만 Train Loss 는 더 낮은 점에 착안하여, '제안하는 방법론이 학습은 더 잘 되지만 Robustness 가 부족하여 새로운 Test Data 에 대해 예측을 잘 하지 못하는 것이 아닐까?'라는 생각을 하게 되었고, 이를 해소하기 위해 매 N Epoch 마다 Shuffle 된 Dataset 과 모든 Class 가 한 번씩 나오게 되는 Dataset 을 번갈아가면서 학습시켜 보았으나[8] 성공하지 못했다.

이어서 시작은 정렬된 Dataset 으로 학습하지만, N 번째 Epoch 부터 Shuffle 된 Dataset 으로 학습하는 것을 시도했지만[9] 성공하지 못했다. Optimizer 를 AdamW 로 바꿔보기도 했지만 큰 성과는 없었다. 계속해서 방안을 모색하던 중, Batch Size 100 을 기준으로 매 Batch 마다 Shuffle 시 100 개 중 보통 65-70 개 종류의 Class 들이 포함된다는 것에 착안하여, 인위적으로 Batch 마다 등장하는 Class 의 개수를 N 개로 제한하여 보았지만[10] 실패하였다.

2-2. Data Filtering

우리는 물체를 인식할 때, 빛의 삼원색에 따라 인지하는 것이 아닌 종합하여 인지하게 된다. 따라서 이미지의 세 Layer(R,G,B)를 모델에 들어오는 순간 Convolution 으로 종합하는 방식을 생각해보았는데, 결과는 좋지 않았다.

---

[6] https://api.wandb.ai/links/oso0310/0uzvnf6t

[7] https://api.wandb.ai/links/oso0310/u6s45ncx

[8] https://api.wandb.ai/links/oso0310/g9hmwhgo

[9] https://api.wandb.ai/links/oso0310/4wgpq95b

[10] https://api.wandb.ai/links/oso0310/uztqgvbc

이어서 이미지 사이즈를 크게 할 수록 성능이 좋아진다는 이미 알려진 사실[11]을 응용해, Linear Layer 를 통해 스스로 입력된 이미지보다 크게 만들어 학습한다면 (예를 들어 32x32 의 입력이 들어왔을 때, 224x224 로 스스로 만들어 학습한다면) 더 성능이 개선될 수 있지 않을까 생각했다. 이에는 이미지의 사이즈가 커질 뿐만 아니라, 모델 자체가 Class 별 원형을 학습하는 효과 또한 있을 것이라 예상했다.

그러다 이미지에 직접 만든 필터를 씌우고 정해진 Epoch 마다 그 필터 부분만을 초기화시켜 스스로 이미지를 증강시키면 좋겠다는 생각을 하게 되었다. 더 나아가 이미지를 처음 모델에 넣은 뒤 나온 예측 결과와 입력을 바탕으로 필터를 만들면 해당 Class 의 원형을 더 잘 학습시킬 수 있다는 생각이 들어 적용시켜 보았고, 결과는 아래 그림 1 과 같다. Accuracy 결과는 현재 로그가 소실되어 확인할 수 없지만, Baseline 보다 좋은 결과를 기록한 적은 없었다.

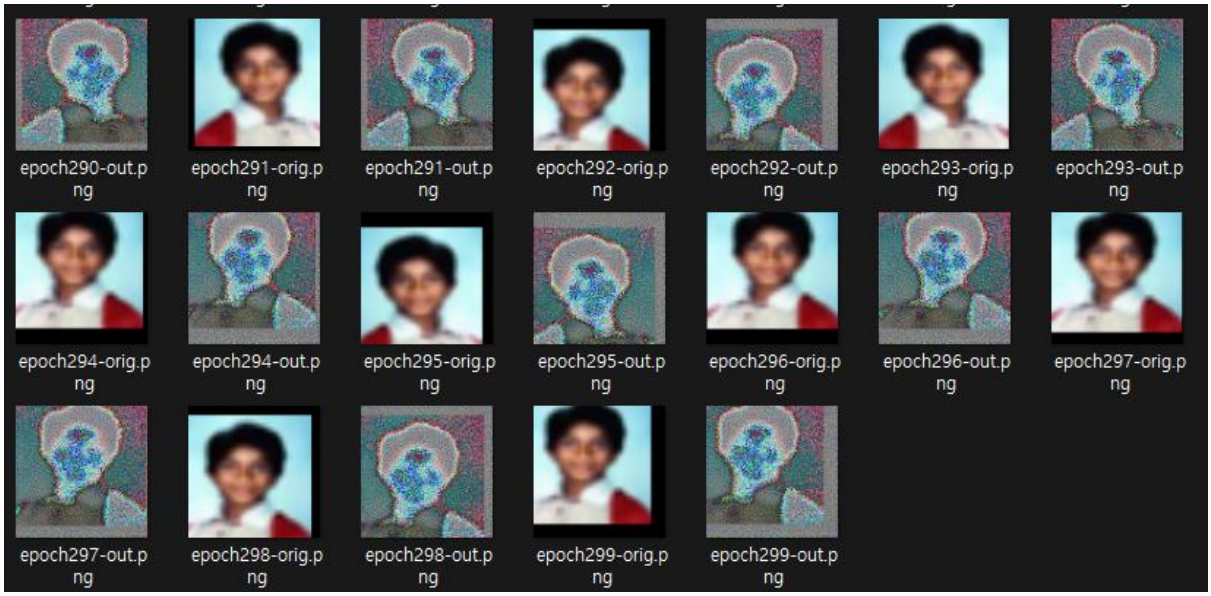

[11] Vajira Thambawita et al., 2021, Impact of Image Resolution on Deep Learning Performance in Endoscopy Image Classification: An Experimental Study Using a Large Dataset of Endoscopic Images, https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8700246/

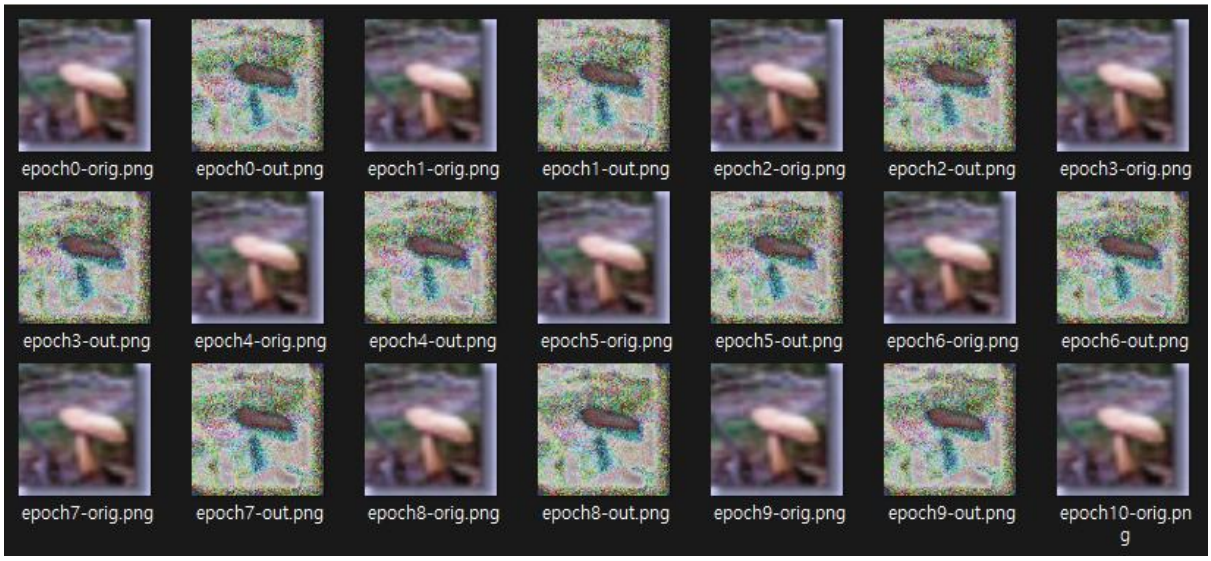

그림 1. Epoch 별 원본 데이터와 필터를 씌운 데이터의 스크린샷. 위 그림은 Train Data 중 무작위로 고른 Class 이고, 아래 그림은 Test Data 중 무작위로 고른 Class 이다. 두 그림 모두에서 모델이 물체의 윤곽을 효과적으로 파악해내고 있음을 확인할 수 있다.

그림을 보면 모델이 중요한 부분을 제외한 다른 부분들은 배경으로 처리하여 무시하는 것처럼 보인다. 그러나 모델은 중요한 부분과 배경을 따로 지시 받아 설정하는 것이 아니기 때문에, 그림 2 와 같은 경우에는 중요한 부분을 한 번 배경으로 오인하여 제거하기 시작하자 계속해서 중요한 부분을 무시하게 되어 결국 잘 학습하지 못하는 것을 확인하였다. 이것이 현재 CNN 모델 학습법의 근본적인 문제일 수도 있겠다는 생각이 들었다.

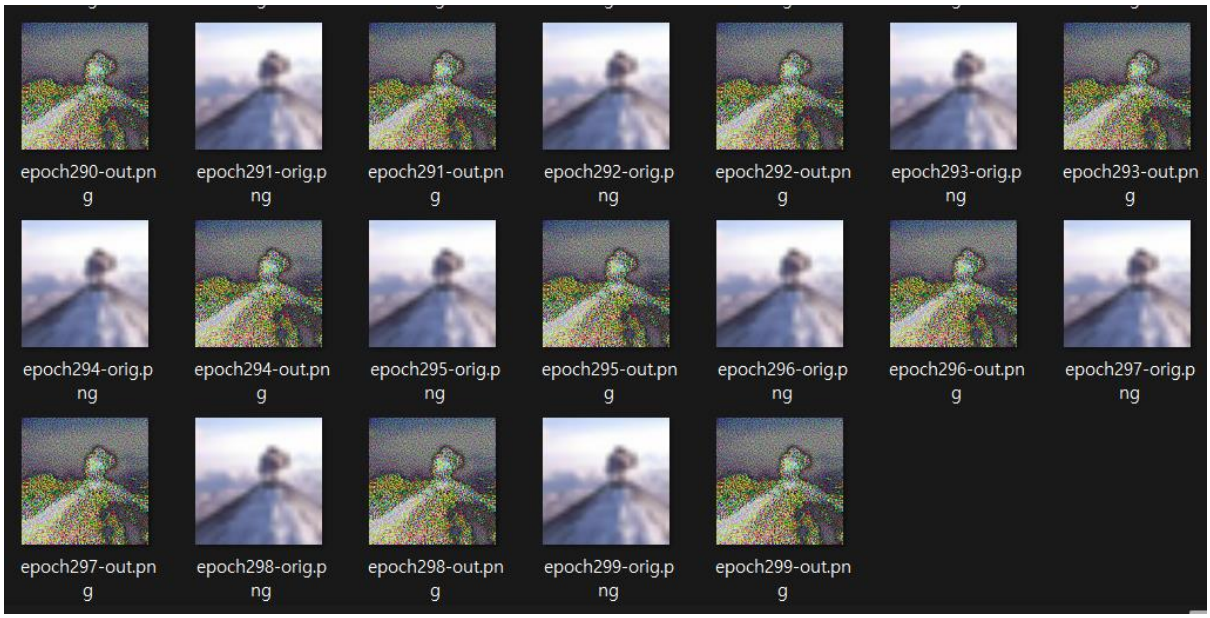

그림 2. Epoch 별 원본 데이터와 필터를 씌운 데이터의 스크린샷. Test Data 중 무작위로 고른 Class 이다. 주목해야 할 목표가 아닌 오른쪽 아래에 집중하는 것을 볼 수 있다.

3. ViT 실험

계속해서 실패를 경험하던 중, 담당교수님으로부터 ViT 을 활용한 Continual Learning 에서 Task 별로 새로운 Token 을 추가하면 적은 비용으로도 성능을 개선할 수 있을지도 모른다는 조언을 듣고, 이에 대한 연구를 시작하게 되었다. 그런데 선행 연구를 탐색하던 중 DyTox 라는 유사한 모델이 이미 있다는 것을 발견하였고, 따라서 DyTox 를 Base 로 하여 성능을 개선하는 연구를 진행하기로 선회하였다.

학습 방식은 Class Incremental Learning 으로, Cifar-100 Dataset 을 바탕으로 Task 별로 10 개의 Class 씩 증강하는 10 Steps, 5 개의 Class 씩 증강하는 20 Steps, 2 개의 Class 씩 증강하는 50 Steps 로 나뉘어져 있다.

3-1. Learnable Class Attention

Task 가 지나 새로운 학습 데이터들이 들어오더라도 기존의 데이터들에 대해서는 중요하게 여기는 부분들이 계속해서 유지된다면 Continual Learning 의 문제인 Catastrophic Forgetting 을 방지할 수 있을 것이라고 생각했다. Class Attention 을 시각화한 결과는 그림 3 과 같고, Task 가 지날수록 중요하게 보는 부분이 옅어진다는 것을 알 수 있다.

이를 개선하기 위한 방법으로 가장 간단하게 Attention 값에 2 를 곱하는 방식으로 값에 할당되는 가중치를 두 배로 향상시켜 보았다. 그러자 Average 기준 10 Steps 에서는 1.5%p 라는 큰 성능 향상이 있었으며, 50 Steps 에서도 소소한 성능 향상을 보였다.

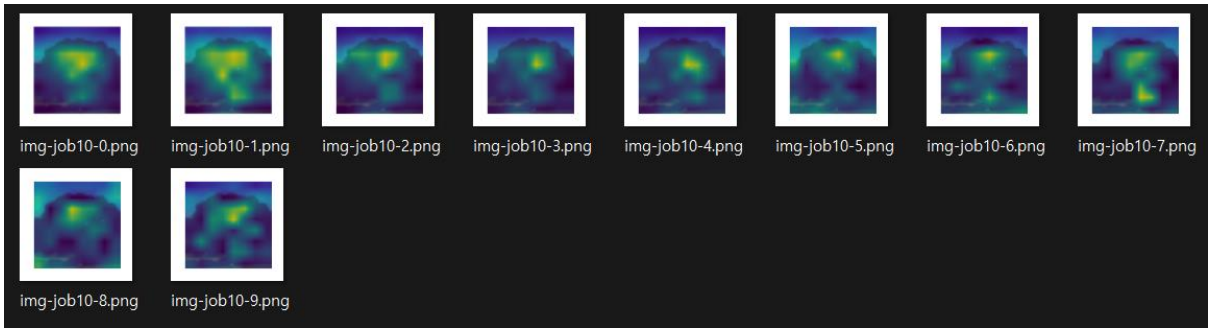

그림 3. DyTox 의 10 Steps 에서 Task 별로 ClassAttention 을 시각화한 스크린샷. Task 가 지날수록 중요하게 보는 부분(노란색)이 옅어지고 있다.

그러나 20 Steps 에서는 큰 성능 향상을 보이지 않았기 때문에 20 Steps 의 성능을 향상시키기 위한 개선법에 대해 생각하던 중, 단순히 2 를 곱하는 것이 아닌 Learnable Parameter 를 곱하는 Learnable Class Attention 방식을 생각해보았다. 그러나 이 방식 또한 성능의 개선을 보이지 않았고, 오히려 10 Steps 의 성능도 저하시켰다. 결과는 표 1 및 WandB Report[12]에서 확인할 수 있다.

[12] https://api.wandb.ai/links/oso0310/s9lp7w0x

CIFAR	10 steps (10-10)			20 steps (5-5)			50 steps (2-2)		
	#P	Avg	Last	#P	Avg	Last	#P	Avg	Last
DyTox	10.73	71.50	57.76	10.74	68.86	51.47	10.77	64.82	45.61
재현		71.47	58.01		68.72	50.51		64.76	44.31
Attn*2		73.00	59.67		68.87	52.24		64.94	44.36
Temperature		71.33	57.78		68.61	51.53			
Temperature2					68.68	50.52			
Temperature4					68.49	50.82			

표 1. Learnable Class Attention 의 Step 별 결과. 첫 번째 행은 DyTox 논문에서의 결과, 두 번째 행은 자체 재현 결과, 세 번째 행은 Attention 에 2 배를 곱한 결과, 네 번째에서 여섯 번째 행은 Learnable Class Attention 을 각각 1, 2, 4 로 초기화한 결과를 나타낸다. 각 Step 별 열은 왼쪽부터 파라미터의 수, 평균 정확도, 마지막 Task 정확도를 나타낸 것이다. 파라미터의 수는 매 시행이 논문의 적힌 값과 같기 때문에 표기를 생략했다.

3-2. Knowledge Distillation 개선

DyTox 에서 Knowledge Distillation 을 위해 사용하는 Teacher Model 이 이전 Task 까지의 학습이 완료된 Model 이었다. 그러나 각 Task 에서 사용하는 학습 데이터에서 이전 Task 까지의 데이터가 차지하는 비중은 몹시 작기 때문에 Teacher Model 은 대부분이 자신도 잘 모르는 새로운 데이터에 대해 Teacher 역할을 수행하고 있었다는 모순적인 상황을 확인할 수 있었다. 그러나 Knowledge Distillation 을 아예 사용하지 않는 것보다는 훨씬 좋은 성능을 보여주었지만, 이 부분을 더욱 개선시킬 수 있을 것이라는 생각이 들었다.

각 Task 만을 학습하는 경우 대개 80 대 후반에서 90 대 초반 정도의 높은 정확도를 보여준다. 이를 활용해 새로운 Task 만 학습한 전문적인 Teacher 모델을 만들어 새롭게 들어오는 데이터에는 새로운 Teacher 가, 옛날 데이터에는 옛날 Teacher 가 각각 Knowledge Distillation 을 수행하는 방식을 구현해보았으나 성능이 좋지 않았다. 추가적으로 각 Task 만을 학습한 모델들을 만들어 각 Weight 들을 더한 후 학습을 시작해보았으나 좋은 결과가 나오지 않았다. 이 실험들의 결과는 WandB Report[13]에서 확인할 수 있다.

3-3. Top-5 활용

Top-5 정확도는 항상 90% 이상의 높은 성능을 보인다. 따라서 이를 활용하여 Top-1 의 성능을 높일 수 있지 않을까 생각했다. Top-5 정확도가 90%라는 것은 5 개 안에 정답이 있을 확률이 90%라는 뜻이기 때문이다. 모델이 Top-5 만을 정교하게 보게 하기 위해서 Loss Function 에 들어가기 전 예측 값에서 상위 5 개를 제외한 모든 값들을 전부 최하위 값으로 만들어 보았다. 해당 실험 결과는 WandB Report[14]에서 확인할 수 있다.

[13] https://api.wandb.ai/links/oso0310/kgtzsczr

[14] https://api.wandb.ai/links/oso0310/848pli0j

3-4. 부분 고정 학습

DyTox 의 Finetuning 과정에서는 이미지를 Token 으로 변환하는 부분인 Self-Attention Blocks (SAB)만을 Freeze 시킨 뒤 Token 으로 Class 를 예측하는 부분인 Task-Attention Blocks (TAB)와 Classifier Head 만을 학습시키고 있다. Finetuning 에 사용되는 데이터는 지금까지 있었던 모든 Task 의 데이터들 중 각 Class 의 평균에 가까운 1000 장을 Class 별로 균등한 수로 뽑아 사용하고 있다.

DyTox 학습 시 항상 Finetuning 과정에서 성능이 많이 향상되는 것을 확인할 수 있다. 따라서 이 Finetuning 과정을 응용하여 Finetuning 이 아닌 본래 학습 때 SAB, TAB, Head 를 일정 Epoch 마다 Freeze 시켜 학습시킨다면 각 모듈이 각자에 맞게 잘 학습할 것이라고 생각했다. 해당 실험 결과는 WandB Report[15]에서 확인할 수 있다.

4. Intentional Forgetting

4-1. 방법론의 발견

위 3-2 의 결과에서 10 개의 Class 만을 학습시키더라도 90%의 정확도를 넘지 못하는 몇 Task 를 확인할 수 있었다. 그래서 DyTox 를 학습시키는 동안 Class 별 결과를 확인해보니, 어떤 Class 는 자신이 처음 도입된 Task 에서 얼마 지나지 않았는데도 나쁜 결과를 내는 경우도 있고 어떤 Class 는 자신이 처음 도입된 Task 에서 많이 지났음에도 높은 결과를 내는 경우도 있었다.

이를 개선하기 위해 여러가지 방안을 생각해 보았다. 가장 먼저 떠오른 것은 Class Incremental Learning 에서 재현용으로 사용되는 Memory 의 구성을 개선하는 것이다. 그러다 문득 에빙하우스의 망각곡선에 따르면 '7 번 잊고 난 후 외우는 것은 긴 시간동안 잊지 않는다는 것'이 떠올랐다. 실험으로 이를 구현해보기 위해 현재 Task 의 데이터만을 포함한 데이터셋 A 와 이전 Task 들의 데이터도 함께 포함한 데이터셋 B 를 번갈아가면서 학습시켜 보았다.

그 결과, A 로 학습시키는 경우 이전 Task 의 Class 들은 잊혀지게 되어 정확도는 떨어지지만, 그 후 B 로 학습시키는 경우 A 로 향상된 성능이 거의 유지되면서 이전 Task 의 Class 들의 성능이 오르게 되어 결국 전체적인 성능도 오르는 것을 확인할 수 있었다. 실험 결과는 아래 표 3 및 WandB Report[16]에서 확인할 수 있다. 10 Steps 과 20 Steps 에서는 좋은 개선을 보였는데, 이는 해당 방법론이 추가적인 메모리와 시간을 요구하지 않는다는 점을 고려하면 꽤나 큰 개선으로 보인다.

그러나 50 Steps 에서는 딱히 좋은 성능을 보여주지 않고 있기 때문에, 50 Steps 에서도 성능을 개선시킬 수 있도록 Epoch 주기를 Tuning 하는 등의 방식을 통해 Forgetting 방법론을 개선시켜야 할 것 같다.

---

[15] https://api.wandb.ai/links/oso0310/k0zog2nn

[16] https://api.wandb.ai/links/oso0310/bly07y98

CIFAR	10 steps (10-10)			20 steps (5-5)			50 steps (2-2)		
	#P	Avg	Last	#P	Avg	Last	#P	Avg	Last
DyTox	10.73	71.50	57.76	10.74	68.86	51.47	10.77	64.82	45.61
재현		71.47	58.01		68.72	50.51		64.76	44.31
exp		72.81	60.47		69.79	52.55		64.72	43.36

표 2. Intentional Forgetting 의 Step 별 결과. 첫 번째 행은 DyTox 논문에서의 결과, 두 번째 행은 자체 재현 결과, 세 번째 행은 Intentional Forgetting 의 결과를 나타낸다. 각 Step 별 열은 왼쪽부터 파라미터의 수, 평균 정확도, 마지막 Task 정확도를 나타낸 것이다. 파라미터의 수는 매 시행이 논문의 적힌 값과 같기 때문에 표기를 생략했다.

4-2. 모델 재현

DyTox 외의 다른 모델들, 특히 현재 SOTA 모델들인 BEEF 와 TCIL 에서도 방법론이 잘 통하는지 확인해 보았다. 각 모델별로 Cifar-100 Dataset 의 Base0 (Inc5, Inc10, Inc20), Base50 (Inc5, Inc10, Inc20)의 6 번씩 실험을 진행하였다. TCIL 은 비교적 잘 재현되었으나[17] BEEF 의 성능이 낮게 나오는 경우들이 있었다[18].

TCIL	Base	B0						B50					
	Steps	5		10		20		2		5		10	
		Avg	Last	Avg	Last	Avg	Last	Avg	Last	Avg	Last	Avg	Last
	Paper	77.72	69.58	77.30	66.41	75.11	63.54	76.42	71.91	74.88	68.58	73.72	66.36
	재현	77.52	69.71	76.59	65.66	74.84	63.10	75.80	71.59	75.02	69.22	74.26	67.37
	IF												

표 3. TCIL 재현 결과.

BEEF	Base	B0									B50								
	Steps	5			10			20			5			10			25		
		No	Avg	Last	No	Avg	Last	No	Avg	Last	No	Avg	Last	No	Avg	Last	No	Avg	Last
	Paper	-	72.31	62.58	-	71.94	60.98	-	69.84	56.71	-	71.70	65.24	-	70.71	63.51	-	66.11	54.36
	재현	3	73.55	65.01	3	71.78	59.21	3	67.89	51.56	4	70.36	64.18	3	67.29	58.35	2	64.07	54.68

표 4. BEEF 재현 결과.

성능이 낮게 나온 BEEF 재현들을 다시 진행하였다. 무작위적 요소들을 통제하고 논문과 같은 Setting 을 유지하기 위해 다시 한 번 확인하고 여러 번 재현을 진행하였다. 그럼에도 성능이 낮게 나오는 경우들이 있었다. 다른 논문들에도 처음 모델을 제안한 논문의 결과가 아닌 자체 재현 결과를 기준으로 삼는 경우가 많다는 것을 확인하여 3 번씩 평균을 낸 결과를 기준으로 삼기로 하였다.

[17] https://api.wandb.ai/links/oso0310/ubcqtrfx

[18] https://api.wandb.ai/links/oso0310/vcizvxwt

FOSTER	Base					B50	
	Inc	10		20		10	
		Avg	Last	Avg	Last	Avg	Last
	Paper	66.49	53.21	68.60	58.67	65.73	57.82
	재현	66.32	54.18	66.28	59.08	67.64	59.59

DER	Base					B50	
	Inc	10		20		10	
		Avg	Last	Avg	Last	Avg	Last
	Paper	69.74	58.59	70.82	62.40	68.24	61.94
	재현	71.89	59.88	71.40	63.49	69.57	62.63

BiC low	Base					B50	
	Inc	10		20		10	
		Avg	Last	Avg	Last	Avg	Last
	Paper	65.08	50.79	67.03	56.22	61.01	49.19
	재현	63.51	44.89	67.37	57.23	55.41	38.93

iCaRL low	Base					B50	
	Inc	10		20		10	
		Avg	Last	Avg	Last	Avg	Last
	Paper	64.42	49.52	67.00	54.23	61.29	52.04
	재현	61.29	42.92	63.34	47.33	55.98	44.88

Replay	Base						
	Inc	10		20		10	
		Avg	Last	Avg	Last	Avg	Last
	Paper	59.31	41.01	60.03	43.08	52.37	41.26
	재현	59.77	42.03	61.48	45.43	53.88	43.53

memo b50 low	Base					B50	
	Inc	10		20		10	
		Avg	Last	Avg	Last	Avg	Last
	Paper	70.20	58.49	70.43	61.39	69.39	62.83
	재현	69.70	57.27	71.09	61.82	65.67	58.52

PODNet	Base					B50	
	Inc	10		20		10	
		Avg	Last	Avg	Last	Avg	Last
	Paper	55.22	36.78	62.96	49.08	64.45	55.21
	재현	55.71	37.18	63.60	49.51	64.42	54.75

WA	Base					B50	
	Inc	10		20		10	
		Avg	Last	Avg	Last	Avg	Last
	Paper	67.09	52.30	68.51	57.97	64.32	55.85
	재현	66.88	53.77	69.13	58.89	64.03	55.95

표 5. WA, iCaRL, DER, MEMO, BiC, FOSTER 재현 결과.

그 외에도 WA[19], iCaRL[20], DER[21], MEMO[22], BiC[23], FOSTER[24] 모델에 대해서도 재현을 진행하였다. 해당 모델들은 Class Incremental Learning 모델들을 정리한 논문[25]의 재현 결과를 참고하여 높은 성능을 보이거나 중요하게 여겨지는 모델들로 선정하였다. 각 모델별로 Cifar-100 Dataset 의 Base0 Inc5, Base0 Inc10, Base0 Inc20, Base50 Inc10 의 4 번씩 실험을 진행하였다. 성능이 낮게 나오는 모델들이 있었지만 대부분은 똑같이 재현되었다.

[19] Bowen Zhao et al., 2019. Maintaining Discrimination and Fairness in Class Incremental Learning, https://arxiv.org/abs/1911.07053

[20] Sylvestre-Alvise Rebuffi et al., 2016, iCaRL: Incremental Classifier and Representation Learning, https://arxiv.org/abs/1611.07725

[21] Shipeng Yan et al., 2021, DER: Dynamically Expandable Representation for Class Incremental Learning, https://arxiv.org/abs/2103.16788

[22] Da-Wei Zhou et al., 2023, A Model or 603 Exemplars: Towards Memory-Efficient Class-Incremental Learning, https://openreview.net/forum?id=S07feAlQHgM

[23] Yue Wu et al., 2019, Large Scale Incremental Learning, https://arxiv.org/abs/1905.13260

[24] Fu-Yun Wang et al., 2022, FOSTER: Feature Boosting and Compression for Class-Incremental Learning, https://arxiv.org/abs/2204.04662

[25] Da-Wei Zhou et al., 2023, Deep Class-Incremental Learning: A Survey, https://arxiv.org/abs/2302.03648

4-3. 모델에 방법론 적용

TCIL 에 방법론을 적용시켜 Baseline 결과와 비교 작업을 진행하였다. 방법론이 잘 통하지 않아 방법론에 여러가지 변화를 주어서 실험하였다. 일정 Epoch 마다 Forgetting 하는 것이 아니라 학습이 끝나기 전 마지막 40 Epoch 시점에서만 Forgetting 을 20 Epoch 정도 진행하는 방식으로 TCIL 의 성능을 개선시킬 수 있었다[26].

TCIL	Base	B0						B50					
	Steps	5		10		20		2		5		10	
		Avg	Last	Avg	Last	Avg	Last	Avg	Last	Avg	Last	Avg	Last
	Paper	77.72	69.58	77.30	66.41	75.11	63.54	76.42	71.91	74.88	68.58	73.72	66.36
	재현	77.52	69.71	76.59	65.66	74.84	63.10	75.80	71.59	75.02	69.22	74.26	67.37
	110120	**77.75**	**69.96**	~~76.47~~	~~65.79~~	75.08	63.38	75.95	71.94	75.37	69.74	74.48	67.61
	130150	77.7	69.98	**76.82**	**66.22**	**75.46**	**69.95**	75.94	71.78	**75.46**	**69.95**	74.43	67.68
	exp10ep160thrallf	77.65	70.1	~~75.37~~	~~64.8~~	75.27	64.48	**76.07**	**72.05**	~~74.77~~	~~68.77~~	**74.81**	**68.42**

표 6. TCIL 모델에 적용 결과. 재현 결과보다 낮은 결과는 취소선, 가장 좋은 결과는 굵게 처리하였다.

방법론에 의해 결과가 많이 상승한 모델이 있고 그렇지 않은 모델들이 있다는 것을 발견하였다. 같은 모델이더라도 Train Scenario 에 따라서 성능이 오를 때도 있고 그렇지 않을 때도 있었다. 따라서 모든 모델과 Scenario 에 일편확률적으로 통할 수 있는 방법론을 찾기 위해 기존의 일정 Epoch 마다 Memory 사용을 껐다 켰었던 방법 외에도 다양한 방법을 시도하였다.

일정 Epoch 이전까지만 방법론을 적용하거나 Plateau 구간에서 성능이 거의 오르지 않는다는 점을 발견해 그 구간에서 새롭게 학습할 데이터를 줄 수 있도록 Plateau 구간에서만 적용해보거나 처음부터 Memory 를 사용하지 않다가 Plateau 구간에서만 Memory 를 사용해 보았다.

DER	Base	B0				B50	
	Inc	10		20		10	
		Avg	Last	Avg	Last	Avg	Last
	Paper	69.74	58.59	70.82	62.40	68.24	61.94
	재현	71.89	59.88	71.40	63.49	69.57	62.63
	160165	**72.09**	**60.28**	~~71.34~~	~~63.16~~	~~69.42~~	~~62.48~~
	162166	~~71.6~~	~~59.99~~	71.54	63.63	69.65	63.33
	81100	~~71.54~~	~~60.28~~	**71.57**	**63.72**	**69.83**	**63.11**
	81110	72.12	61.34	71.45	63.85	69.59	62.79

iCaRL low	Base	B0				B50	
	Inc	10		20		10	
		Avg	Last	Avg	Last	Avg	Last
	Paper	64.42	49.52	67.00	54.23	61.29	52.04
	재현	61.29	42.92	63.34	47.33	55.98	44.88
	0150rate2	61.46	43.83	63.77	48.95	~~55.12~~	~~44.78~~
	080rate2	61.66	44.24	63.91	48.59	~~54.54~~	~~44.47~~

memo b50 low	Base	B0				B50	
	Inc	10		20		10	
		Avg	Last	Avg	Last	Avg	Last
	Paper	70.20	58.49	70.43	61.39	69.39	62.83
	재현	69.70	57.27	71.09	61.82	65.67	58.52
	80100	70.33	58.69	71.1	61.52	65.67	58.61
	80150rate2	69.75	58.55	71.04	62.08	~~65.41~~	~~58.86~~

[26] https://api.wandb.ai/links/oso0310/r701zxup

표 7. DER, iCaRL, MEMO 모델에 적용 결과. 재현 결과보다 낮은 결과는 취소선, 가장 좋은 결과는 굵게 처리하였다.

어떤 모델이든 성능을 향상시키는 데는 성공하였으나, 통일된 방법을 찾는 데는 실패하였다. 방법론 자체도 전체적으로 학습이 잘 되게 만드는 것이 아니라 일부 Class 의 성능은 오르고 일부는 내리는데 오른 폭이 더 높을 경우에 결과가 좋게 보이는 눈속임일 수도 있겠다는 생각이 들었다.

이에 가장 처음의 관측(항상 잘 맞추는 Class 와 그렇지 않은 Class 가 있다)으로 돌아가서 메모리 구성을 효율적으로 개선하는 방식의 새로운 방법론을 설계하고 있다. 쉬운 Class 와 어려운 Class 를 나누기 위해 Validation Statistics 를 참고하려 했다. Validation Set 5%를 뺀 95%로 학습시켜 보았는데, 중반 이후로 성능이 오히려 증가하는 이상한 상황을 발견[27]하였다. 다른 모델들에도 실험해본 결과로는 Last Epoch 의 결과는 향상되지만 Average 결과는 감소되는 경향을 보였다.

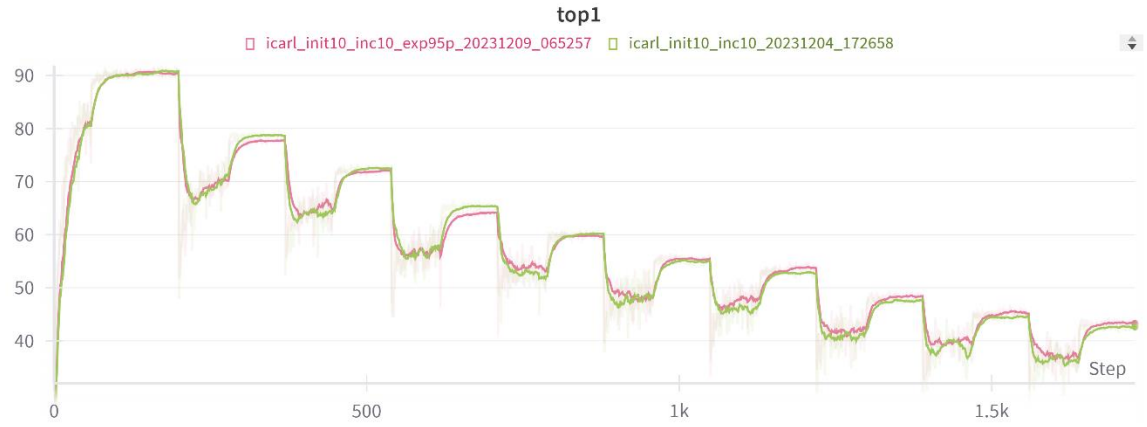

그림 4. iCaRL 모델에 Cifar-100 을 100% 전부 학습시킨 결과(초록색)과 95%만 학습시킨 결과 (핑크색).

5. 결론

지금까지의 연구는 관찰을 통해 문제를 찾아내고 그 문제를 해결하기 위한 방안들을 찾기 위해 최대한 다양한 아이디어들을 Brainstorming 하고 직접 구현해보는 방식으로 CNN 의 개선 방안을 찾기 위한 연구 과정을 단련하기 위해 노력하였다. 그 결과, 여러 번의 실패 끝에 Intentional Forgetting 이라는 하나의 가능성을 찾아냈다.

그러나 모든 모델에 통하는 통일된 방법을 찾지 못해 현재 Train Data 의 평균과 표준편차 데이터를 활용해 어려운 Class 와 쉬운 Class 를 나누어 Forgetting 대상을 변경하는 방식에 대해 연구하고 있다.

이후 내년 초 학회 제출을 목표로 논문화를 진행할 예정이다.

[27] https://api.wandb.ai/links/oso0310/z3f3rjd8